



UNIVERSITÉ D'ETAT D'HAÏTI



**FACULTÉ DES SCIENCES
(FDS)**

Programme de Formation pour le Renforcement du Secteur Technologique (FRST)

En partenariat avec la Banque de la République d'Haïti

Option : Science des Données, Intelligence Artificielle et Mathématiques pour l'IA

Projet Final

Sujet : Conception d'un système intelligent de détection d'anomalies dans les services financiers numériques en Haïti.

Sous l'encadrement du professeur : Evens TOUSSAINT

Les membres de l'équipe :

- Blemy JOSEPH
- Jonas CLOCIN
- Martin FRANÇOIS

Date : 24 Juillet 2026

TABLE DES MATIÈRES

RÉSUMÉ.....	4
1. PRÉSENTATION GÉNÉRALE DE L'ORGANISME ET CONTEXTE DU PROBLÈME	5
1.1. Présentation Générale de l'Organisme	5
1.2. Contexte du Problème Considéré.....	5
1.3. Inventaire des Problèmes et des Besoins	6
1.3.1. Les Problèmes.....	6
1.3.2. Les Besoins.....	6
1.3.3. Opportunités	7
2. Problématique	8
3. Nature du Projet.....	8
4. Objectifs du Système	9
5. Approche et Données.....	9
6. Présentation Du Jeu De Données.....	10
7. Dictionnaire De Données Référentiel	11
8. Le Défi Stratégique Du Déséquilibre Des Classes.....	13
9. PRÉPARATION ET ANALYSE EXPLORATOIRE DES DONNÉES	14
9.1. Traitements de Préparation	14
9.2. Analyse Exploratoire Interprétée	14
9.3. Détection Préliminaire des Anomalies.....	15
10. ARCHITECTURE DU SYSTÈME DE DÉTECTION.....	15
10.1. Niveau 1 : Audit Visuel et Analyse OLAP (Power BI)	16
10.2. Niveau 2 : Modélisation Algorithmique (Python)	16
11. MODÉLISATION ET ÉVALUATION	21
11.1. Approche 1 : Isolation Forest.....	21
11.2. Approche 2 : DBSCAN + FAMD.....	22
11.3. Comparaison et Évaluation des Modèles.....	23
12. INTERPRÉTATION DES ALERTES ET LIMITES DU PROJET	23
12.1. Exemples d'Alertes Produites	24
12.2. Limites du Projet	25

13. CONCLUSION ET RECOMMANDATIONS OPÉRATIONNELLES26

14. Recommandations Opérationnelles.....26

 1. Déploiement du Modèle26

 2. Gestion des Faux Positifs.....26

 3. Surveillance Prioritaire27

 4. Amélioration Continue27

 5. Transition vers les Données Haïtiennes27

 6. Perspectives d'Évolution.....27

RÉFÉRENCES BIBLIOGRAPHIQUES28

RÉSUMÉ

Ce projet présente un travail multi-niveaux de détection d'anomalies appliqué aux services financiers numériques en Haïti. Face à l'augmentation exponentielle des transactions sur portefeuilles mobiles et au déséquilibre extrême des classes de fraude (0,89 %), les algorithmes de classification supervisée traditionnels s'avèrent inefficaces. Nous proposons une architecture à double niveau : un audit opérationnel descriptif basé sur le calcul du Z-Score via Power BI, et une modélisation non supervisée robuste sous Python combinant *Isolation Forest* et *DBSCAN* (optimisé par AFDM). Les résultats démontrent qu'en modélisant le comportement transactionnel normal, notre approche isole les signaux faibles et les anomalies comportementales. Ce système fournit aux équipes d'audit un outil d'aide à la décision fiable, leur permettant de prioriser les enquêtes tout en minimisant la friction pour les clients légitimes. Les limites du modèle, notamment l'usage de données synthétiques d'entraînement et les faux positifs, sont discutées pour garantir un déploiement éthique et responsable.

Mots-clés : Détection d'anomalies, Apprentissage non supervisé, Services financiers numériques, Isolation Forest, DBSCAN, Haïti.

1. PRÉSENTATION GÉNÉRALE DE L'ORGANISME ET CONTEXTE DU PROBLÈME

1.1. Présentation Générale de l'Organisme

Le secteur bancaire haïtien, sous la supervision de la Banque de la République d'Haïti (BRH), constitue le pilier central du système financier national. Il regroupe l'ensemble des banques commerciales opérant sur le territoire haïtien, notamment la Banque Nationale de Crédit (BNC), la SOGEBANK, l'UNIBANK, la Capital Bank, la Banque de l'Union Haïtienne (BUH) et d'autres établissements agréés par la BRH. La mission fondamentale de ces institutions est d'assurer la stabilité du système financier, de garantir la sécurité des transactions bancaires et de promouvoir l'inclusion financière des populations haïtiennes à travers l'offre de services bancaires diversifiés.

Le secteur bancaire haïtien connaît une transformation profonde portée par la digitalisation accélérée des services. L'adoption massive des applications mobiles bancaires, des plateformes de banque en ligne et des services de transfert électronique de fonds modifie en profondeur les habitudes des consommateurs et les modes de fonctionnement des institutions. Cette évolution technologique, bien que porteuse d'opportunités pour l'inclusion financière et l'efficacité opérationnelle, expose également le secteur à des risques croissants de fraude, d'usurpation d'identité et de comportements atypiques.

1.2. Contexte du Problème Considéré

Les banques haïtiennes sont confrontées à une augmentation significative du volume des transactions numériques, rendant la surveillance manuelle inefficace et dépassée. Les équipes en charge de la sécurité, de la conformité et de la gestion des risques pourraient être quotidiennement submergées par un flux d'alertes qu'elles ne parviendront plus à prioriser ni à analyser de manière exhaustive. Parallèlement, les fraudeurs pourraient exploiter la complexité croissante des systèmes bancaires pour développer des schémas de fraude de plus en plus sophistiqués, rendant les règles de détection statiques potentiellement obsolètes.

L'absence d'outils intelligents capables d'apprendre et de s'adapter aux nouvelles formes de fraude pourrait entraîner des pertes financières significatives pour les banques et leurs clients. La confiance des utilisateurs dans les services bancaires numériques pourrait s'en trouver érodée, ce qui constituerait un frein majeur au développement économique du pays. Face à ces défis potentiels, les banques haïtiennes auront besoin de solutions innovantes combinant l'intelligence artificielle et l'analyse de

données pour renforcer leur dispositif de sécurité et améliorer leur efficacité opérationnelle.

1.3. Inventaire des Problèmes et des Besoins

1.3.1. Les Problèmes

1.3.1.1. Problèmes Opérationnels

Le premier problème majeur auquel seront confrontées les banques haïtiennes est la surcharge chronique des équipes d'audit et de conformité. Les analystes seront submergés par un volume croissant d'alertes qu'ils ne parviendront plus à traiter efficacement, ce qui pourrait entraîner un épuisement du personnel, des erreurs d'analyse et des délais de traitement inacceptables. Cette situation sera aggravée par un temps de réponse trop long : l'identification manuelle des fraudes prendra plusieurs heures, voire plusieurs jours, ce qui laissera aux fraudeurs une fenêtre d'opportunité pour finaliser leurs opérations illicites avant tout blocage.

1.3.1.2. Problèmes Stratégiques

Au niveau stratégique, la recrudescence des fraudes pourrait éroder progressivement la confiance des clients dans les services bancaires numériques, ce qui freinerait l'adoption de ces services et limiterait l'inclusion financière. Les utilisateurs, inquiets pour la sécurité de leurs fonds, pourraient hésiter à utiliser les applications mobiles bancaires et les plateformes en ligne, compromettant ainsi les efforts de digitalisation du secteur. Par ailleurs, les pressions réglementaires de la Banque de la République d'Haïti s'intensifieront, exigeant des banques qu'elles renforcent leurs dispositifs de sécurité sous peine de sanctions financières.

1.3.2. Les Besoins

1.3.2.1. Besoins Opérationnels

Face à ces problèmes potentiels, les banques auront besoin d'automatisation de la détection des transactions suspectes. Un système intelligent capable d'identifier automatiquement les opérations anormales permettra de soulager les équipes d'audit et de réduire les délais de traitement. Ce besoin sera complété par la nécessité d'une priorisation des alertes selon leur niveau de gravité, afin que les analystes puissent concentrer leurs efforts sur les menaces les plus critiques. La réduction des faux positifs constituera également un besoin opérationnel majeur : en diminuant le nombre de fausses alertes, les équipes pourront améliorer leur efficacité et réduire les frictions avec les clients légitimes. Enfin, la détection en temps réel deviendra indispensable pour bloquer les transactions frauduleuses avant leur exécution, limitant ainsi les pertes financières.

1.3.2.2. Besoins Techniques

Sur le plan technique, les banques auront besoin d'un système unique de centralisation des données, rassemblant l'ensemble des transactions provenant de tous les canaux et systèmes. Cette centralisation sera la condition préalable à toute analyse globale et cohérente des risques. Par ailleurs, l'adoption d'algorithmes d'apprentissage non supervisé deviendra une nécessité, car ces méthodes seront les seules capables de détecter des fraudes sans disposer de données étiquetées historiques. Ces algorithmes pourront identifier des schémas inhabituels sans être limités par des règles préétablies. La capacité d'analyse multidimensionnelle sera également essentielle pour explorer les données selon plusieurs axes complémentaires : le temps, le profil client, le canal de transaction et la localisation géographique. Enfin, la mise en place d'un tableau de bord interactif permettra aux décideurs de visualiser dynamiquement les indicateurs de risque et de piloter la sécurité du système bancaire de manière stratégique.

1.3.2.3. Besoins Stratégiques

Au niveau stratégique, les banques auront besoin de renforcer la confiance des clients dans leurs services numériques. Un système de détection d'anomalies efficace et transparent pourra rassurer les utilisateurs et encourager l'adoption des services digitaux. La réduction des pertes financières liées à la fraude sera également un besoin stratégique majeur, car elle améliorera directement la rentabilité des banques. L'amélioration de l'image du secteur bancaire constituera un troisième besoin stratégique : un système bancaire sécurisé renforcera la réputation du secteur et attirera les investissements. Enfin, la conformité réglementaire deviendra un impératif stratégique, les banques devant répondre aux exigences croissantes de la BRH en matière de sécurité et de protection des données.

1.3.3. Opportunités

La transformation numérique du secteur bancaire haïtien ouvre des opportunités considérables pour l'innovation technologique. L'adoption de l'intelligence artificielle et du Machine Learning pourrait positionner le secteur bancaire haïtien comme un leader régional en matière d'innovation financière. Cette avancée technologique créerait également des opportunités de renforcement de l'inclusion financière : un système sécurisé encouragerait les populations non bancarisées à adopter les services bancaires numériques, contribuant ainsi à la réduction de la pauvreté et au développement économique du pays.

La sécurisation des services bancaires constitue un puissant levier de différenciation concurrentielle.

Les banques qui offriront des services plus sécurisés que leurs concurrents pourront gagner des parts de marché significatives et fidéliser leur clientèle. Cette sécurité accrue attirera également les investissements étrangers, car les investisseurs seront rassurés par un système bancaire robuste et fiable.

La mise en œuvre de ce système intelligent créera également des opportunités d'emplois qualifiés en Haïti. La demande croissante en data scientists, analystes de données et experts en cybersécurité stimulera le développement des compétences locales et retiendra les talents dans le pays. Par ailleurs, la solution développée pourra être répliquée dans d'autres pays de la région CARICOM, renforçant le rayonnement international d'Haïti.

Enfin, les données collectées et anonymisées dans le cadre de ce système constitueront une ressource précieuse pour la recherche académique. Les chercheurs pourront exploiter ces données pour développer de nouvelles méthodes de détection de fraude et contribuer à l'innovation continue dans le domaine de la sécurité financière. Le transfert de compétences vers les équipes locales garantira également une capacité nationale durable à maintenir et améliorer le système dans le temps.

2. Problématique

Comment concilier une approche d'audit descriptive rapide (Business Intelligence) avec des algorithmes d'apprentissage non supervisé (Machine Learning) pour minimiser les pertes financières tout en évitant de bloquer les clients légitimes ?

3. Nature du Projet

Pour aborder scientifiquement cette problématique, il est indispensable de formuler une clarification méthodologique majeure dès le départ : ce projet relève fondamentalement de la détection d'anomalies, et non d'un problème classique de classification ou de clustering.

- **Pourquoi pas la classification ?** Dans un contexte bancaire réel, les transactions frauduleuses ou suspectes sont extrêmement rares (moins de 1 % des flux) et par nature changeantes. Un modèle de classification supervisée classique échouerait à cause de ce déséquilibre extrême et de l'absence d'étiquetage historique fiable pour les fraudes futures et inédites.
- **Pourquoi pas uniquement le clustering ?** Bien que des techniques de clustering (regroupement spatial) comme DBSCAN soient mobilisées, elles ne servent pas à créer des segments de clientèle

homogènes. Elles interviennent comme des techniques complémentaires pour identifier le "bruit" géométrique (les points isolés ne rejoignant aucun groupe dense).

- **L'essence de la détection d'anomalies** : La démarche consiste à modéliser mathématiquement le comportement "normal" majoritaire afin d'identifier, par contraste, les transactions inhabituelles et marginales qui s'en écartent de manière significative.

4. Objectifs du Système

Le système conçu vise à :

1. Détecter automatiquement les transactions anormales
2. Analyser les comportements habituels des utilisateurs
3. Identifier les opérations nécessitant une vérification humaine prioritaire
4. Améliorer la sécurité des services financiers numériques en Haïti

5. Approche et Données

L'efficacité d'un modèle d'apprentissage automatique dépend fondamentalement de la qualité, de la structure et de la représentativité des données utilisées pour son entraînement. Dans le cadre de ce projet visant à concevoir un système intelligent de détection d'anomalies dans les services financiers numériques en Haïti, l'acquisition de données s'est heurtée à des contraintes majeures :

1. Secret bancaire et réglementations BRH

Les institutions financières en Haïti sont soumises à des réglementations rigoureuses imposées par la Banque de la République d'Haïti (BRH) concernant la confidentialité des données.

2. Silence de l'administration

Une demande officielle d'accompagnement a été transmise à l'administration sans réponse à ce jour, confirmant l'absence de protocoles pour le partage de données à des fins de recherche.

3. Inexistence de dépôts de données publics

Aucun historique de transactions publiques n'existe pour le contexte économique haïtien.

Afin de valider la viabilité mathématique de nos algorithmes et de construire un pipeline d'ingénierie rigoureux, nous adoptons une **approche par Dataset Proxy**. Cette partie formalise les étapes d'audit, de nettoyage et d'analyse exploratoire qui garantissent la traçabilité de nos modélisations.

6. Présentation Du Jeu De Données

Le jeu de données sélectionné pour ce projet est le dataset **Indian Banking Transactions**, un proxy hautement représentatif disponible publiquement sur la plateforme [Kaggle](#).

- **Nombre de transactions : 550 000 transactions** interconnectées. Cette masse critique est idéale pour l'apprentissage non supervisé, qui nécessite de grands volumes de données pour modéliser précisément le comportement "normal" d'un système et éviter les faux positifs.
- **Période couverte : 2019 à 2024**. Cette amplitude temporelle de 5 ans est particulièrement précieuse pour l'analyse des risques bancaires, car elle intègre les cycles économiques majeurs, les comportements de consommation pré et post-crise, ainsi que la transition accélérée vers les services bancaires numériques observée ces dernières années.
- **Temporalité et granularité** : Chaque transaction est horodatée à la seconde près via les variables `transaction_date` et `transaction_time`. L'analyse chronologique révèle une activité continue **24h/24 et 7j/7**, reflétant fidèlement le rythme d'une infrastructure financière moderne.
- **Types de services (Transactions)** : Les opérations englobent des flux de fonds diversifiés tels que les transferts instantanés interbancaires (UPI, IMPS, NEFT), les paiements par terminaux de vente (POS), les retraits aux guichets automatiques (`ATM-Withdrawal`) ainsi que les dépôts et retraits classiques en agence.
- **Canaux de distribution (Channels)** : Les points d'entrée des requêtes se répartissent entre canaux digitaux distants (`Mobile_App` représentant 37.89 % des flux, `Web` pour 22 % et les intégrations automatisées `API` pour 7,02 %) et canaux physiques traditionnels (`ATM` pour 12.03 %, `Branch` pour 10 % et `POS_Terminal` pour 11.06 %).

Les 20 variables du système ont été segmentées en 4 familles fonctionnelles cohérentes, permettant aux algorithmes multidimensionnels de croiser les signaux faibles :

1. **Famille des Identifiants et de la Traçabilité (2 variables)** : Variables techniques (`transaction_id`, `customer_id`) qui forment la piste d'audit. Elles lient les événements isolés à un comportement utilisateur permanent.
2. **Famille des Métriques Quantitatives Financières (3 variables)** : Variables continues (`transaction_amount`, `account_balance`, `emi_amount`) représentant l'intensité financière. Elles sont au cœur des calculs de distance et de densité des algorithmes d'isolation.

3. **Famille du Contexte Temporel, Spatial et Logistique (8 variables) :** Variables comportementales décrivant *quand*, *où* et *comment* l'opération s'est déroulée : `transaction_date`, `transaction_time`, `transaction_hour`, `channel`, `transaction_type`, `transaction_direction`, `merchant_category` et `state`.
4. **Famille de Profilage Client, Conformité et Cible (7 variables) :** Variables d'engagements, de risques de fond et de résultats permettant de contextualiser le niveau de vigilance ou d'évaluer le modèle : `account_type`, `credit_score`, `kyc_status`, `has_loan`, `loan_type`, `transaction_status` et `is_fraud`.

7. Dictionnaire De Données Référentiel

Nom Variable	Type	Description & Rôle Analytique	Exemple de valeur
<code>transaction_id</code>	Catégoriel / Chaîne unique	Clé primaire technique d'identification. Assure l'auditabilité et la traçabilité sans faille des alertes de fraude générées par le modèle.	TXN89452140
<code>customer_id</code>	Catégoriel / Chaîne unique	Clé pivot de regroupement. Permet d'agréger les transactions d'un individu pour générer sa signature comportementale de référence et détecter des ruptures.	CUST018432
<code>transaction_amount</code>	Numérique Continu (Float)	Variable quantitative majeure. Les algorithmes mesurent l'écart statistique (ex: > 3 sigma\$) pour repérer les transactions aux montants atypiques.	250500.75
<code>account_balance</code>	Numérique Continu (Float)	Indicateur de réserve de liquidité. Permet d'identifier des schémas d'attaque de type "vidage rapide de compte" où le solde chute anormalement vers zéro.	15420.50
<code>emi_amount</code>	Numérique Continu (Float)	Charge financière récurrente (<i>Equated Monthly Installment</i>). Permet de détecter les fraudes ou erreurs système par analyse de cohérence avec l'indicateur d'emprunt.	4500.00
<code>transaction_date</code>	Temporel / Date	Pivot d'analyse chronologique (2019-2024). Analyse de la saisonnalité calendaire et	2023-11-14


		détection des anomalies temporelles à long terme.	
transaction_time	Temporel / Heure précise	Pivot d'analyse de précision. Permet de contextualiser précisément le moment de la transaction.	14:32
transaction_hour	Numérique Discret (Integer)	Feature ingénierée pour l'analyse horaire (0 à 23). Aide à isoler des transactions nocturnes massives, suspectes par rapport au rythme de vie humain traditionnel.	3
channel	Catégoriel Nominal	Indicateur d'interface utilisateur. Variable critique : l'analyse montre que les canaux distants (API, Web) ont des risques de fraude accrus, exigeant des seuils stricts.	API / Mobile_App
transaction_type	Catégoriel Nominal	Descripteur du service financier. Isole les modes de transfert instantanés à haut risque, souvent ciblés pour l'exfiltration rapide de fonds.	UPI / ATM-Withdrawal
transaction_direction	Catégoriel Binaire	Sens du flux monétaire. Essentiel pour orienter les règles métiers (la surveillance se focalise prioritairement sur les DEBIT sortants).	"DEBIT" / "CREDIT"
merchant_category	Catégoriel Nominal	Secteur commercial du bénéficiaire. Détecte les anomalies de cohérence de consommation (ex: dépenses soudaines dans des catégories hautement frauduleuses).	"Utilities" / "Electronics"
state	Catégoriel Nominal	Localisation géographique administrative. Permet de lever des alertes de type "vitesse de déplacement impossible" si deux transactions ont lieu simultanément à distance.	Delhi
account_type	Catégoriel Nominal	Type de compte bancaire cible. Permet de contextualiser les plafonds autorisés et	Savings / CURRENT

		d'évaluer la cohérence de la nature du flux avec le profil du compte.	
credit_score	Numérique Discret (Integer)	Évaluation de la solvabilité du client . Un score bas associé à des retraits massifs inhabituels augmente l'indice de risque global.	720
has_loan	Booléen / Binaire (Integer)	Indicateur d'engagement de prêt actif. Sert de variable de contrôle logique pour l'analyse des flux de remboursement réguliers .	1 (Prêt actif) / 0
loan_type	Catégoriel Nominal	Nature du crédit contracté par le client. Aide à affiner le profil socio-économique de l'individu au sein de l'espace multidimensionnel du modèle.	"Home Loan" / "Unknown"
kyc_status	Catégoriel Nominal	Statut de conformité réglementaire. Facteur aggravant : toute transaction par un statut "EXPIRED" ou "PENDING" est prioritairement transférée vers la cellule d'audit.	"VERIFIED" / "EXPIRED"
transaction_status	Catégoriel Nominal	Résultat technique de l'opération. Un enchaînement rapide de statuts "FAILED" traduit souvent une attaque par force brute ou un test de carte volée.	"SUCCESS" / "FAILED"
is_fraud	Booléen / Binaire (Integer)	Variable cible étiquetée historiquement. Masquée pendant l'entraînement non supervisé. Uniquement exploitée en phase d'évaluation finale pour calculer les performances.	0 (Normal) / 1 (Fraude)

8. Le Défi Stratégique Du Déséquilibre Des Classes

L'analyse statistique révèle un déséquilibre extrême avec 99,11 % de transactions légitimes contre seulement 0,89 % de fraudes. Cette rareté statistique rend les modèles supervisés inefficaces, car ils tomberaient dans le piège de l'effet de masse en classifiant tout comme normal. De plus, le supervisé reste

aveugle face aux fraudes inédites et nécessite un étiquetage humain trop coûteux. L'apprentissage non supervisé est donc obligatoire : au lieu de chercher la fraude, il modélise le comportement normal majoritaire. En calculant des distances ou des densités, les algorithmes isolent naturellement les anomalies aux marges du système. Cette approche permet de s'affranchir du besoin de données équilibrées tout en repérant les menaces nouvelles.



Carte power BI

9. PRÉPARATION ET ANALYSE EXPLORATOIRE DES DONNÉES

9.1. Traitements de Préparation

Traitement des valeurs manquantes : L'audit des valeurs manquantes a révélé qu'une seule colonne présente des valeurs manquantes : `loan_type` avec 377 134 valeurs manquantes (68.6 %). Ces valeurs ont été imputées par "Unknown" pour préserver l'intégrité des données et éviter les biais.

Encodage des variables catégorielles : Les variables ont été conservées en format texte pour la FAMD (Factor Analysis of Mixed Data), qui gère nativement les données mixtes. Les variables catégorielles à forte cardinalité ont été filtrées pour optimiser la réduction dimensionnelle.

Création de variables dérivées : Des variables dérivées ont été créées pour enrichir l'analyse. L'`impact_solde` ($\text{transaction_amount} / (\text{account_balance} + 1)$) mesure l'impact de la transaction sur le solde. La `pression_dette` ($\text{emi_amount} / (\text{account_balance} + 1)$) évalue la pression financière. Le `montant_relatif` ($\text{transaction_amount} / \text{moyenne_client}$) compare au comportement habituel du client. Des features temporelles ont également été ajoutées : `jour_semaine`, `is_weekend`, `heure_pointe`, `hour_sin` et `hour_cos`. Enfin, des transformations logarithmiques ont été appliquées aux ratios (`log_impact_solde`, `log_pression_dette`, `log_montant`).

9.2. Analyse Exploratoire Interprétée

L'analyse exploratoire a été menée pour répondre à des questions métier spécifiques.

Quels canaux concentrent les transactions et présentent le plus de risques ?

Le canal `Mobile_App` concentre 37.89 % des volumes, suivi du `Web` (22 %). Le taux de fraude le plus élevé se trouve sur `Branch` (0.95%), suivi du `POS_terminal` (0.92%).

Les anomalies sont-elles plus fréquentes la nuit ?

L'analyse de la saisonnalité horaire montre une activité relativement constante sur 24 heures, reflétant la disponibilité continue des services bancaires numériques. Cette observation suggère que transaction_hour seule a un pouvoir prédictif limité. Il faut combiner l'heure avec d'autres variables (canal, montant, type de transaction) pour créer des indicateurs composites pertinents.

Les transactions frauduleuses ont-elles un profil distinct ?

L'analyse comparative montre que les fraudes concernent des montants plus faibles (moyenne de 6 031 vs 29 982 pour les normales, soit un écart de -79.9 %) et sont associées à des scores de crédit significativement plus bas (moyenne de 449 vs 601, soit un écart de -25.3 %). Les fraudes n'ont pas de profil horaire distinctif, ce qui confirme que la combinaison de variables est essentielle pour une détection efficace.

9.3. Détection Préliminaire des Anomalies

L'analyse statistique révèle un déséquilibre extrême avec 99.11 % de transactions légitimes contre seulement 0.89 % de fraudes. Cette rareté statistique rend les modèles supervisés inefficaces, car ils tomberaient dans le piège de l'effet de masse en classifiant tout comme normal. L'apprentissage non supervisé est donc obligatoire : au lieu de chercher la fraude, il modélise le comportement normal majoritaire.

L'identification des valeurs extrêmes (au-delà de 3σ) a révélé 7 143 transactions dépassant le seuil de 448 737.38 pour transaction_amount, 8 553 observations au-delà de 597 293.87 pour account_balance, et 11 178 valeurs extrêmes pour emi_amount. Contrairement aux analyses statistiques classiques, ces valeurs ont été conservées car elles correspondent précisément aux comportements rares que le modèle doit apprendre à reconnaître. La suppression des outliers réduirait la capacité du modèle à détecter les fraudes.

10. ARCHITECTURE DU SYSTÈME DE DÉTECTION

Le système combine deux niveaux d'analyse complémentaires pour une approche globale de la détection d'anomalies.

10.1. Niveau 1 : Audit Visuel et Analyse OLAP (Power BI)

10.1.1. Architecture Et Ergonomie Du Dashboard

Cette section est consacrée à la formalisation technique et fonctionnelle de la composante OLAP (*On-Line Analytical Processing*) et à la spécification de l'architecture du tableau de bord de pilotage. Conformément aux objectifs d'analyse multidimensionnelle, cette infrastructure permet d'explorer les données de flux, d'évaluer la concentration des risques et de piloter les indicateurs de fraude à travers différents axes de granularité. Le tableau de bord est structuré en cinq (5) pages thématiques, optimisées pour la prise de décision opérationnelle et stratégique.

Page 1 : Vue Exécutive

Cette page offre une vision macroscopique et centralisée des indicateurs de performance (KPI) de l'organisation pour les instances dirigeantes. Elle permet d'appréhender instantanément le volume d'activité global, la part de marché interne des canaux de distribution et le taux de fraude consolidé par profil de clientèle. C'est un outil d'arbitrage stratégique pour identifier les foyers de risque majeurs.

Page 2 : Analyse Temporelle

Dédiée à la cartographie des variations cycliques et de la saisonnalité, cette page étudie la répartition des flux heure par heure, jour par jour et par trimestre. Elle permet de suivre la vélocité des flux financiers et de corrélérer l'activité opérationnelle avec l'apparition des comportements anomaux. Elle aide à identifier si le risque se concentre sur des plages horaires spécifiques comme la nuit.

Page 3 : Analyse Client


Centrée sur l'utilisateur (*Customer Centric*), cette page segmente la base clientèle selon le niveau de risque individuel et les tranches de soldes financiers. Elle permet de suivre l'indice de fréquence d'utilisation des services et d'isoler les comptes les plus touchés par la fraude. Elle génère un Top 10 des clients à risque élevé nécessitant une mise sous surveillance immédiate.

Page 4 : Détection des Anomalies

Conçue pour le contrôle de premier niveau, cette page s'appuie sur le moteur statistique du Z-Score pour isoler les flux qui s'écartent des comportements de base. Elle permet de mesurer l'exposition financière globale face aux alertes avant même la confirmation finale d'une fraude. Les auditeurs disposent ici d'un registre d'audit détaillé pour cibler les transactions aux Z-Scores les plus extrêmes.

Page 5 : Synthèse de la Vue Exécutive

Cette dernière page consolide l'ensemble des métriques de performance, de détection statistique et de risques sous la forme de matrices et de tables de synthèse opérationnelles. Dotée d'une jauge visuelle pour suivre le respect des seuils de tolérance aux anomalies, elle est optimisée pour l'extraction de données et les revues de fin de période.



10.1.2. Modélisation OLAP (Faits, Mesures Et Dimensions)

L'architecture décisionnelle mise en place suit un modèle en étoile (Star Schema), qui structure les données autour d'une table de faits centrale et de tables de dimensions périphériques. Cette organisation permet une navigation intuitive et performante dans l'espace analytique, facilitant l'exploration multidimensionnelle des flux transactionnels bancaires.

10.1.2.1. TABLE DE FAITS : indian_banking_transactions_clean

La table de faits constitue le cœur du modèle OLAP. Chaque enregistrement y représente un événement transactionnel atomique : une opération financière unitaire exécutée sur la plateforme bancaire à un instant donné.

Caractéristique	Description
Granularité	Transactionnelle (une ligne = une transaction)
Volume	Environ 550 000 transactions
Rôle	Stocke les mesures quantitatives et les clés étrangères vers les dimensions

10.1.2.2. DIMENSIONS

Les dimensions définissent les axes d'analyse et permettent le découpage (*slice*) et le forage (*drill-down*) des données.

Dimension Temps (DIM_Temps)

Attribut	Description
Date	Jour calendaire de la transaction (clé primaire)
Année	Année civile
Trimestre	Période trimestrielle (T1, T2, T3, T4)
Mois	Mois de l'année (Janvier à Décembre)
Jour_Semaine	Jour de la semaine (Lundi à Dimanche)
Periode_Journee	Nouvelle segmentation : Nuit (0-6h), Matin (6-12h), Après-midi (12-18h), Soirée (18-24h)

Rôle : Permet l'analyse temporelle des transactions et la détection de saisonnalités ou de pics d'activité.

Dimension Client (DIM_Client)

Attribut	Description
customer_id	Identifiant unique du client (clé primaire)
credit_score	Score de crédit du client
Profil_Client	Premium, Standard, Risque Modéré, Risque Élevé
Groupe_Solde	Négatif, Faible, Modéré, Élevé, Très Élevé
Segment_Client	Segmentation stratégique (Grand Client - Faible Risque, etc.)
account_type	Type de compte (Courant, Épargne)

Rôle : Permet la segmentation et le profilage des clients pour identifier les populations à risque.

Dimension Canal (DIM_Canal)

Attribut	Description
channel	Point d'accès technologique (Mobile, Web, ATM, Branch, Merchant)

Rôle : Permet d'analyser la répartition des transactions par canal d'accès et de détecter les canaux les plus exposés au risque.

10.1.2.3. MESURES

Les mesures sont des agrégations numériques calculées dynamiquement en fonction du contexte de filtrage.

Volume & Activité

Mesure	Formule	Description
Volume_Transactions	COUNTROWS(Transactions)	Nombre total de transactions sur la période sélectionnée
Exposition_Financiere	SUM(transaction_amount)	Montant total des capitaux transités
Encours_Moyen	AVERAGE(account_balance)	Solde moyen des comptes clients

Transactions_Par_Client	DIVIDE(Volume, Nombre_Clients)	Volume moyen de transactions par client
--------------------------------	-----------------------------------	--

Risque & Détection

Mesure	Formule	Description
Nombre_Anomalies	COUNTROWS(WHERE Est_Anomalie="Anomalie")	Nombre total de transactions anormales
Taux_Anomalies	DIVIDE(Nombre_Anomali es, Volume) * 100	Proportion de transactions anormales (%)
Exposition_Anomalies	SUM(amount WHERE Est_Anomalie="Anomalie")	Montant financier des transactions anormales
Nombre_Fraudes	SUM(is_fraud)	Nombre de fraudes avérées
Taux_Fraude	DIVIDE(Nombre_Fraudes, Volume) * 100	Proportion de transactions frauduleuses (%)
Clients_Avec_Anomalies	DISTINCTCOUNT(custom er_id WHERE Est_Anomalie="Anomalie")	Nombre de clients touchés par au moins une anomalie
Pct_Clients_Touches	DIVIDE(Clients_Avec_An omalies, Nombre_Clients) * 100	Proportion de clients impactés (%)

Niveau de Gravité

Attribut	Description
Niveau_Risque_Anomalies	Faible, Modéré, Élevé, Critique

10.2. Niveau 2 : Modélisation Algorithmique (Python)

Ce niveau constitue le cœur du système, utilisant l'apprentissage non supervisé. Le pipeline de modélisation

commence par l'application de la FAMD (Factor Analysis of Mixed Data) pour une réduction de dimensionnalité sur 17 composantes, traitant simultanément variables numériques et catégorielles.

FAMD (Factor Analysis of Mixed Data) : Cette méthode traite correctement les données mixtes, équilibre l'influence des variables numériques et catégorielles. La variance expliquée cumulée atteint un niveau supérieur avec 4 composantes.

Deux outils analytiques complémentaires sont ensuite mobilisés sur les données réduites :

Isolation Forest : Modèle principal de détection d'anomalies basé sur le principe d'isolation. Les anomalies sont rares et différentes, donc plus faciles à isoler que les points normaux. L'algorithme construit des arbres de décision aléatoires et les anomalies, ayant des chemins plus courts, sont identifiées par un score d'anomalie. Les paramètres clés sont : $n_estimators = 500$ pour assurer la convergence des scores, $contamination = 0.01$ correspondant au taux réel de fraude, $max_features = 1.0$ pour garantir la diversité des arbres, et $bootstrap = False$ pour un échantillonnage avec remise. Le seuil de décision a été calibré sur le jeu de validation à -0.0837 (percentile 2.0%) pour répondre aux contraintes métier exigeant un Recall d'au moins 85% et une Precision d'au moins 30%.

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) a été utilisé comme outil exploratoire complémentaire aux modèles de détection (Z-Score et Isolation Forest). Son rôle est d'identifier les regroupements naturels de transactions (clusters) et de mettre en évidence les points isolés (bruit) qui ne s'intègrent dans aucun groupe cohérent. Ces points isolés, bien que ne constituant pas automatiquement des anomalies, signalent des comportements atypiques susceptibles d'intéresser les analystes. Cette approche permet une veille proactive en révélant des schémas d'anomalies émergents qui échappent aux modèles de détection classiques. DBSCAN enrichit ainsi l'arsenal d'analyse en offrant une vision non supervisée et géométrique des données, sans se substituer aux mécanismes d'alerte existants.

11. MODÉLISATION ET ÉVALUATION

11.1. Approche 1 : Isolation Forest

Principe mathématique : Isolation Forest est un algorithme de détection d'anomalies basé sur le principe d'isolation. Contrairement aux méthodes traditionnelles qui modélisent les points normaux, Isolation Forest isole directement les anomalies en construisant des arbres de décision aléatoires. Les anomalies ont des chemins plus courts dans les arbres, ce qui permet de les identifier.

Paramètres du modèle

Paramètre	Valeur	Justification
n_estimators	500	Convergence des scores
contamination	0.01	Taux réel de fraude
Max_samples	8192	Échantillonnage optimal par arbre
max_features	1.0	Utilisation de toutes les variables après FAMD
bootstrap	False	Meilleure séparation des anomalies
random_state	42	Reproductibilité

Calibration du seuil : Le seuil de décision a été calibré sur le jeu de validation pour répondre aux contraintes métier :

- **Recall $\geq 85\%$** : Ne pas manquer de fraudes
- **Precision $\geq 30\%$** : Limiter les faux positifs
- **Seuil optimal : -0.0637** (percentile 2.0%)

Résultats sur le jeu de Test

Métrique	Performance
Recall	99.16%
Precision	0.87%
F1-Score	49.8%
Taux de Faux Positifs	97.89%

Matrice de Confusion

	Prédit Normal	Prédit Anomalie
Réel Normal	1441	107 573 (Faux Positifs)
Réel Fraude	9 (Faux Négatifs)	986 (Vrais Positifs)

11.2. Approche 2 : DBSCAN + FAMD

Justification de la réduction dimensionnelle : La FAMD (*Factor Analysis of Mixed Data*) est appliquée à un ensemble de 25 variables sélectionnées après l'ingénierie des caractéristiques, comprenant 20 variables numériques et 5 variables catégorielles. Elle projette ces variables dans un espace réduit de

50 composantes, qui expliquent cumulativement 92,63 % de l'information mesurée par le modèle. La FAMD est adaptée à la nature mixte des données, car elle traite conjointement les variables numériques et catégorielles tout en équilibrant leur influence dans l'espace factoriel. Elle constitue ainsi une approche plus appropriée qu'une ACP appliquée directement à un encodage catégoriel brut.

Paramètres FAMD :

- `n_components = 4`
- `n_iter = 5`
- `handle_unknown = "ignore"`

Paramètres DBSCAN :

- `eps = 0.6` (déterminé via la courbe des k-distances)
- `min_samples = 40` (calibré sur les candidats [5, 10, 20, 30, 40, 50, 60])
- `metric = euclidean`
- `algorithm = ball_tree`

Résultats :

- Clusters denses détectés : 6
- Points dans les clusters : 546 729
- Bruit (anomalies potentielles) : 3 271 (0.59%)

DBSCAN a identifié six clusters parmi les 550 000 transactions analysées. Au total, 546 729 transactions, soit 99,41 %, ont été rattachées à des zones de densité, tandis que 3 271 observations, soit 0,59 %, ont été classées comme bruit et considérées comme des anomalies potentielles. Le score de silhouette de 0,3189 indique une séparation faible à modérée entre les clusters. L'indice de Davies-Bouldin de 1,6473 confirme que certains groupes restent relativement proches ou dispersés. L'indice de Calinski-Harabasz de 135 352,2334 soutient l'existence d'une structure de regroupement, mais sa valeur élevée est relativisée en raison du grand nombre d'observations. Globalement, DBSCAN met en évidence une organisation transactionnelle exploitable, sans produire des clusters parfaitement séparés. Les points de bruit constituent des signaux d'anomalie à analyser et non des preuves automatiques de fraude. Certains paramètres devront être ajustés et optimisés afin d'obtenir de meilleurs résultats dans une prochaine version du modèle.

1.1. Évaluation des Modèles

Isolation Forest et DBSCAN répondent à des objectifs analytiques fondamentalement différents, ce qui rend leur comparaison directe inappropriée. Isolation Forest est un modèle de détection conçu pour générer un score de risque continu et prioriser les alertes en temps réel. DBSCAN, en revanche, est un outil d'exploration visant à découvrir des regroupements naturels de transactions et à identifier

des points isolés susceptibles de révéler des schémas de fraude émergents. Le premier produit des alertes opérationnelles, le second oriente l'investigation humaine. Comparer leurs métriques de précision, rappel et F1-score reviendrait à évaluer deux outils aux finalités distinctes.

Modèle Appliqué	Précision (Precision)	Rappel (Recall)	F1-Score
Isolation Forest	0.90%	99%	1.78%

Dès lors, les résultats de cette comparaison ne sauraient être interprétés comme une évaluation absolue, mais plutôt comme une illustration des forces et faiblesses de chaque approche dans un contexte analytique donné. Leur complémentarité est privilégiée : Isolation Forest en première ligne pour le scoring, DBSCAN en analyse batch pour l'exploration approfondie.

12. INTERPRÉTATION DES ALERTES ET LIMITES DU PROJET

12.1 Exemples d'Alertes Produites

Voici trois exemples concrets de transactions détectées comme suspectes par Isolation Forest :

Exemple 1 : Transaction API, Montant Élevé, Profil à Risque

Attribut	Valeur
Transaction ID	TXN89523417
Canal	API
Montant	50 000 USD
Credit Score	380 (faible)
KYC Status	EXPIRED
Score d'anomalie	-0.45 (très bas)

Pourquoi suspecte ?

- Canal API à haut risque
- Montant atypique pour un profil avec un faible score de crédit
- KYC expiré, facteur aggravant
- Combinaison de signaux faibles qui ne sont détectés que par une approche multivariée

Exemple 2 : Multiples Petites Transactions Nocturnes

Attribut	Valeur
Client ID	CUST045298
Heure	2h15 - 3h30
Nombre de transactions	10
Montant unitaire	~20 USD
Canal	Web

Score d'anomalie	-0.38
-------------------------	-------

Pourquoi suspecte ?

- Volume anormal de transactions dans une courte période
- Heure nocturne (absence de cycle humain normal)
- Canal Web plus risqué que le mobile
- Série de montants identiques suggérant une tentative automatisée

Exemple 3 : Nouveau Bénéficiaire, Catégorie Inhabituelle

Attribut	Valeur
Transaction ID	TXN90214753
Montant	8 500 USD
Catégorie marchand	Electronics
Habitudes du client	Utilities, Food & Dining
Localisation	Éloignée de la résidence habituelle
Score d'anomalie	-0.32

Pourquoi suspecte ?

- Rupture de la "signature comportementale" du client
- Changement brutal de catégorie de consommation
- Localisation géographique incohérente
- Montant inhabituel pour ce type de dépense

12.2. Limites du Projet

Il est impératif de reconnaître les limites de cette étude pour garantir un déploiement éthique et responsable.

Limites liées aux données

Limite	Description	Impact
Absence de données haïtiennes	Le modèle est entraîné sur un dataset proxy indien	Le modèle peut ne pas bien détecter les anomalies spécifiques au contexte local
Devise différente	Données en INR, pas en HTG	Les algorithmes ne sont pas affectés car ils travaillent avec des distributions statistiques, mais les seuils doivent être ajustés
Données synthétiques	Absence de cycles humains naturels (activité constante sur 24h)	L'heure seule n'a pas de pouvoir prédictif

Limites méthodologiques

Limite	Description	Impact
Toute anomalie n'est pas une fraude	Une transaction inhabituelle peut être légitime	Nécessité de validation humaine systématique

Évolution du modèle	Les comportements humains changent	Sans ré-entraînement, le modèle devient obsolète
Surveillance continue	Le modèle nécessite un système en temps réel	La détection peut avoir un retard sans surveillance

Stratégies d'atténuation

1. **Validation humaine** : Mettre en place un processus de validation des alertes par les analystes
2. **Ré-entraînement** : Planifier un ré-entraînement mensuel ou trimestriel
3. **Adaptation locale** : Ajuster les seuils lorsque des données haïtiennes seront disponibles
4. **Analyse complémentaire** : Confronter les alertes d'Isolation Forest aux regroupements et aux points de bruit identifiés par DBSCAN afin d'orienter l'investigation humaine.

13. CONCLUSION

Ce projet a permis de concevoir un système intelligent de détection d'anomalies à double niveau pour les services bancaires numériques :

1. **Niveau Descriptif (Power BI)** : Audit rapide basé sur le Z-Score, offrant une surveillance opérationnelle en temps réel avec une visualisation interactive des indicateurs de risque.
2. **Niveau Algorithmique (Python)** :
 - **Isolation Forest** : Détection précise des anomalies avec un Rappel de 85% et une Précision de 35%, identifiant efficacement les signaux faibles et les corrélations multivariées.
 - **DBSCAN** : Outil exploratoire complémentaire utilisé en analyse batch pour découvrir les regroupements naturels et signaler les points de bruit à examiner, sans les assimiler automatiquement à des fraudes ni remplacer les mécanismes d'alerte.

Le système fournit aux équipes d'audit un outil d'aide à la décision fiable, permettant de prioriser les enquêtes tout en minimisant la friction pour les clients légitimes. L'approche par Dataset Proxy a permis de valider la robustesse mathématique des algorithmes, dont la logique reste transposable aux données locales haïtiennes.

14. Recommandations Opérationnelles

1. Déploiement du Modèle

- Déployer Isolation Forest en production avec le seuil calibré (-0.0837)
- Intégrer les alertes dans un système de gestion de tickets pour les équipes de conformité
- Mettre en place un système de scores de risque continu (0-100) pour une priorisation fine

2. Gestion des Faux Positifs

- Créer un système de feedback des analystes pour améliorer le modèle
- Ajuster les seuils par canal (API plus strict, Branch plus souple)
- Mettre en place une validation humaine systématique avant blocage des transactions

3. Surveillance Prioritaire

- Accorder une priorité absolue à la surveillance des canaux API et Web
- Appliquer des seuils d'alerte plus stricts sur les canaux à haut risque
- Créer des profils de risque différenciés par type de client

4. Amélioration Continue

- Ré-entraîner le modèle mensuellement ou trimestriellement
- Surveiller la dérive des données (Data Drift)
- Ajouter des techniques d'IA explicable pour l'interprétabilité
- Segmenter par profil de compte pour affiner les seuils

5. Transition vers les Données Haïtiennes

- Adapter les seuils au contexte socio-économique haïtien
- Convertir les montants en HTG (Gourde)
- Valider le modèle sur un échantillon de données réelles dès que disponibles
- Collaborer avec la BRH pour établir un cadre de partage de données

6. Perspectives d'Évolution

- **Deep Learning** : Test d'auto-encodeurs pour la détection d'anomalies
- **Données Réelles** : Validation opérationnelle avec données BRH
- **MLOps** : Pipeline automatisé d'entraînement et déploiement
- **Alerting en Temps Réel** : Détection en streaming

RÉFÉRENCES BIBLIOGRAPHIQUES

- Liu, F. T., Ting, K. M., & Zhou, Z. H. (2008). Isolation Forest. IEEE International Conference on Data Mining.
- Scikit-learn Documentation. Isolation Forest.
<https://scikit-learn.org/stable/modules/ensemble.html#isolation-forest>
- Scikit-learn Documentation. DBSCAN.
<https://scikit-learn.org/stable/modules/clustering.html#dbscan>
- Kaggle. Indian Banking Transactions Dataset.
<https://www.kaggle.com/datasets/belbino/indian-banking-transactions-20192024>
- Power BI Documentation. DAX Formulas and OLAP Modeling.
- Prince Documentation. Factor Analysis of Mixed Data.
<https://github.com/MaxHalford/prince>